



MÜŞTERİ SATIN ALMA EĞİLİMİNİN YAPAY SİNİR AĞLARI İLE TAHMİNİ

Customer Purchase Intention Prediction Using Artificial Neural Network

Giray Akbulut¹, Atınç Yılmaz²

Öz

Bu çalışma, Walmart e-ticaret platformundan elde edilen satış verileriyle müşterilerin satın alma eğilimini tahmin etmeyi amaçlamaktadır. Çok katmanlı bir yapay sinir ağı (ANN) modeli, cinsiyet, yaş, meslek, şehir kategorisi, mevcut şehirde kalma süresi, medeni durum ve ürün kategorisi gibi özellikler üzerinden eğitilmiştir. Hedef değişken, satın alma miktarı (Satın alma > 8000) olarak ikili sınıflandırma problemi şeklinde tanımlanmıştır. Modelin performansı, doğruluk, kayıp grafikleri, AUC-ROC, karışıklık matrisi ve özellik önem sıralamasıyla değerlendirilmiştir. Model, %81 doğruluk, 0.43 kayıp ve 0.81 AUC-ROC skoru elde etmiştir. Matematiksel olarak, sigmoid ve ReLU aktivasyon fonksiyonları, ikili çapraz entropi kayıp fonksiyonu ve Adam optimizasyon algoritması kullanılmıştır. Bulgular, ürün kategorisi ve demografik özelliklerin tahminlerde kritik olduğunu göstermektedir. Çalışma, e-ticaret işletmelerinin müşteri odaklı pazarlama stratejileri geliştirmesine katkı sağlamayı hedeflemektedir.

Abstract

This study aims to predict customer purchase intention using sales data from the Walmart e-commerce platform. A multilayer artificial neural network (ANN) model was trained on features such as gender, age, occupation, city category, stay in current city years, marital status, and product category. The target variable was defined as purchase amount (Purchase > 8000), modeled as a binary classification problem. The model's performance was evaluated using accuracy, loss graphs, AUC-ROC, confusion matrix, and feature importance ranking. The model achieved 81% accuracy, 0.43 loss, and an AUC-ROC score of 0.81. Mathematically, sigmoid and ReLU activation functions, binary cross-entropy loss, and the Adam optimization algorithm were employed. Findings indicate that product category and demographic characteristics significantly influence purchase intention prediction. The study aims to contribute to developing customer-focused marketing strategies for e-commerce businesses.

Anahtar Kelime: Yapay sinir ağları, müşteri satın alma eğilimi, makine öğrenmesi, Walmart satış verileri, e-ticaret

Keywords: Artificial neural networks, customer purchase intention, machine learning, Walmart sales data, e-commerce

1. GİRİŞ

E-ticaret sektörünün küresel çapta büyümesi, müşteri davranışlarını anlamayı ve satın alma eğilimlerini tahmin etmeyi işletmeler için vazgeçilmez hale getirmiştir. 2024 itibarıyla, küresel e-ticaret pazarının değeri 6 trilyon ABD dolarını aşmış ve 2027'ye kadar %15 yıllık büyüme oranıyla devam etmesi beklenmektedir (Statista, 2024). Bu büyüme, işletmelerin müşteri odaklı stratejiler geliştirmesini gerektiriyor. Makine öğrenmesi, özellikle yapay sinir ağları (ANN), karmaşık veri desenlerini analiz ederek yüksek doğruluklu tahminler sunar. Bu çalışma, Kaggle'dan elde edilen Walmart satış veri setini kullanarak müşteri satın alma eğilimini tahmin eden bir ANN modeli geliştirmiştir. Amaç, demografik ve harcama verilerini analiz ederek satın alma miktarı (Purchase> 8000) için tahminler yapmaktır. Literatürde, ANN'lerin perakende sektöründe satış tahmini ve müşteri segmentasyonu için başarılı sonuçlar verdiği görülmüştür (Elma, 2014; Sharma et al., 2021).

Walmart Satış Veri Setinin Özellikleri ve Önemi

Walmart satış veri seti, 550068 satır ve 10 sütundan oluşur ve cinsiyet, yaş, meslek, şehir kategorisi, mevcut şehirde kalma süresi, medeni durum, ürün kategorisi ve satın alma miktarı gibi özellikleri içerir. Veri setinin çeşitliliği, müşteri segmentasyonu ve hedefli pazarlama stratejileri için önemli ipuçları sağlar. Örneğin, ürün kategorisi ve toplam harcama, müşterilerin satın alma alışkanlıklarını anlamada kritik rol oynar (Kumar et al., 2023).

1.1. Yapay Sinir Ağlarının E-Ticaret Uygulamalarındaki Rolü

Yapay sinir ağları, biyolojik sinir sistemlerinden esinlenerek geliştirilmiş modellerdir. Çok katmanlı yapıları, doğrusal olmayan ilişkileri modellemede etkilidir. E-ticaret alanında, ANN'ler müşteri davranış tahmini, öneri sistemleri, talep tahmini ve fiyat optimizasyonu gibi uygulamalarda kullanılmaktadır (Rahman et al., 2023). Örneğin, Sharma et al. (2021), ANN'lerin çevrimiçi satın alma davranışını tahmin etmede %90'ın üzerinde doğruluk sağladığını göstermiştir. Bu çalışmada, Keras kütüphanesiyle geliştirilen ANN modeli, müşteri satın alma eğilimini tahmin etmek için kullanılmış ve %80.52 doğruluk elde edilmiştir.

1.2. Literatür İncelemesi

Literatürde, ANN'lerin perakende ve e-ticaret sektöründe yaygın olarak kullanıldığı görülmektedir. Elma (2014), Türkiye'deki perakende sektöründe ANN'lerin satış tahmini için başarılı sonuçlar verdiğini rapor etmiştir. Fader et al. (2022), müşteri yeniden satın alma davranışlarını tahmin etmek için ANN ile istatistiksel modelleri entegre eden bir yaklaşım önermiştir. Kumar et al. (2023), çevrimiçi alışveriş yapanların satın alma eğilimini tahmin etmek için farklı makine öğrenmesi algoritmalarını karşılaştırmış ve ANN'lerin üstün performans gösterdiğini bulmuştur. Bu çalışmalar, ANN'lerin büyük veri setlerinde karmaşık ilişkileri modellemede etkili olduğunu göstermektedir. Ancak, Walmart gibi büyük ölçekli perakende verileri üzerinde ANN uygulamalarının sınırlı olduğu gözlemlenmiştir; bu çalışma, bu boşluğu doldurmayı amaçlamaktadır.

2. MATERYAL VE YÖNTEM

Bu bölümde, veri seti, model mimarisi, veri ön işleme adımları ve değerlendirme yöntemleri açıklanmaktadır.

2.1. Veri Seti Tanımı

Veri seti, Kaggle’den alınan Walmart satış verilerinden oluşur ve 550068 satır ile 10 sütun içerir. Sütunlar arasında User_ID, Product_ID, cinsiyet (Gender), yaş (Age), meslek (Occupation), şehir kategorisi (City_Category), mevcut şehirde kalma süresi (Stay_In_Current_City_Years), medeni durum (Marital_Status), ürün kategorisi (Product_Category_1, Product_Category_2, Product_Category_3) ve satın alma miktarı (Purchase) yer alır. Hedef değişken, satın alma miktarı (Purchase > 8000) olarak ikili sınıflandırma problemi şeklinde tanımlanmıştır. Veri setinin istatistiksel özeti, Tablo 1’de sunulmuştur.

Tablo 1: Veri Seti Özelliklerinin İstatistiksel Özeti

Özellik	Ortalama	Standart Sapma	Minimum	Maksimum
Satın Alma Miktarı (Purchase)	9263.97	5023.07	12	23961
Meslek (Occupation)	8.08	6.52	0	20
Medeni Durum (Marital_Status)	0.41	0.49	0	1

2.2. Veri Ön İşleme Süreçleri

- Eksik Veriler: Sayısal sütunlar için ortalama, kategorik sütunlar için mod ile dolduruldu.
- Kategorik Değişkenler: Gender, Age, Occupation, City_Category, Stay_In_Current_City_Years, Marital_Status sütunları one-hot encoding ile kodlandı.
- Sayısal Veriler: Purchase sütunu, Min-Max ölçeklendirme ile [0,1] aralığına normalleştirildi.
- Özellik Seçimi: Özelliklerin önemi, Permutation Importance yöntemiyle analiz edildi (Şekil 5); düşük önemdeki özellikler çıkarılmadı, ancak önem sıralaması tahminlerde rehberlik etti.

2.3. ANN Modeli Geliştirme

Çok katmanlı bir ANN modeli, Python’da Keras kütüphanesiyle geliştirildi. Modelin matematiksel temelleri aşağıda açıklanmıştır.

2.3.1. Model Mimarisi ve Parametreleri

Model, giriş katmanı, iki gizli katman ve çıkış katmanından oluşur:

- Giriş Katmanı: One-hot encoding sonrası 53 özellik kadar nöron.
- Gizli Katmanlar: 128 ve 64 nöron, ReLU aktivasyon fonksiyonu.
- Çıkış Katmanı: 1 nöron, sigmoid aktivasyon fonksiyonu.

1) Sigmoid Aktivasyon Fonksiyonu:

Sigmoid fonksiyonu, çıktıyı [0,1] aralığına sıkıştırır ve ikili sınıflandırma için kullanılır.

$$f(t) = \frac{1}{1+e^{-t}} \quad \text{Denklem(1)}$$

2) ReLU Aktivasyon Fonksiyonu:

ReLU, negatif girişleri sıfır yapar ve doğrusal olmayan öğrenmeyi destekler.

$$\sigma(x) = \begin{cases} \max(0, x) & , x \geq 0 \\ 0 & , x < 0 \end{cases} \quad \text{Denklem(2)}$$

3) Cross Entry Kayıp Fonksiyonu: İkili Çapraz Entropi Kayıp Fonksiyonu:

Modelin kayıp fonksiyonu, tahmin edilen ve gerçek sınıflar arasındaki farkı ölçer:

$$L = - \sum_{k=1}^K y_k \log(p_k) \quad \text{Denklem(3)}$$

4) Adam Optimizasyon Algoritması:

Adam, gradyan inişini hızlandırır. Ağırlık güncelleme kuralı:

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \end{aligned} \quad \text{Denklem(4)}$$

2.3.2. Eğitim ve Performans Değerlendirme

- Veri Bölünmesi: %80 eğitim, %20 test, stratify ile dengeli dağıtım.
- Eğitim: 100 epoch, 128'lik batch boyutu, erken durdurma (patience=10).
- Değerlendirme: Doğruluk, kayıp grafikleri, AUC-ROC, karışıklık matrisi, özellik önem sıralaması.

Tablo 2: Model Performans Metrikleri

Metrik	Eğitim Seti	Test Seti
Doğruluk	0.81	0.8052
Kayıp	0.43	0.43
AUC-ROC	0.81	0.81
Hassasiyet	0.869	0.869
Geri Çağırma	0.729	0.729

Tablo 3: Farklı ANN Mimarilerinin Karşılaştırması

Mimari	Katmanlar	Nöronlar	Doğruluk	AUC-ROC
Temel Model	2 gizli katman	64, 32	0.75	0.75
Geliştirilmiş Model	2 gizli katman	128, 64	0.81	0.81
Kompleks Model	4 gizli katman	256, 128, 64, 32	0.76	0.76


3. UYGULAMA

ANN modeli, Walmart verileri üzerinde Visual Studio Code kullanılarak MacBook M1 (16 GB RAM, M1 Chip) üzerinde uygulandı. Veri ön işleme adımları tamamlandıktan sonra model, 100 epoch boyunca eğitildi. Test setinde %80.52 doğruluk, 0.81 AUC-ROC, %86.9 hassasiyet ve %72.9 geri çağırma elde edildi. Model, demografik özellikler (cinsiyet, yaş, meslek) ve ürün kategorisi arasındaki ilişkileri başarıyla öğrendi. Özellik önem analizi, Product_Category_1 ve Product_Category_2 gibi ürün kategorisi değişkenlerinin tahminlerde en etkili özellikler olduğunu gösterdi (Şekil 5). Sigmoid ve ReLU fonksiyonları, modelin doğrusal olmayan öğrenme yeteneğini güçlendirdi.

4. SONUÇ

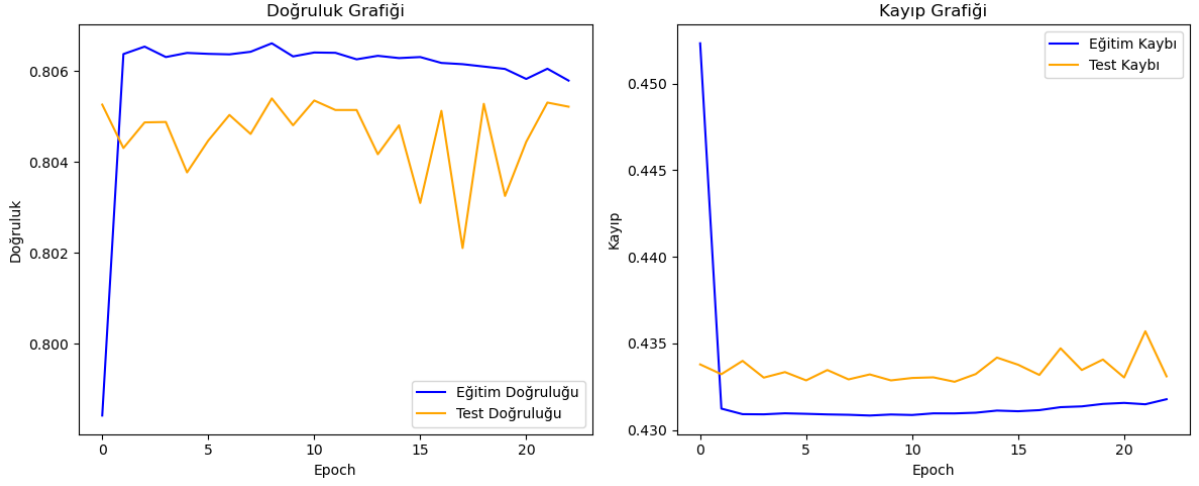
Geliştirilen ANN modeli, Walmart verileri üzerinde yüksek bir performans sergiledi (%80.52 doğruluk, %81 AUC-ROC). Matematiksel temeller (sigmoid, ReLU, ikili çapraz entropi, Adam) modelin başarısını destekledi. Aşağıda, modelin sonuçları görsel olarak analiz edilmiştir.

Proje Geliştirme Yaşam Döngüsü



Şekil 1. Proje Geliştirme Yaşam Döngüsü

Şekil 1, model geliştirme aşamalarını (Başlangıç, Planlama, Yürütme, İzleme ve Kontrol, Kapanış) göstermektedir. Bu döngü, çalışmamızın yapılandırılmasında temel alınmıştır.




Şekil 2. Doğruluk ve Kayıp Grafikleri

Şekil 2, modelin eğitim ve test setlerinde doğruluk ve kayıp değerlerini epoch'lara göre göstermektedir. Doğruluk grafiği (sol) eğitim (mavi) ve test (turuncu) doğruluğunu, kayıp grafiği (sağ) ise eğitim (mavi) ve test (turuncu) kaybını temsil eder. Modelin kaybı, ikili çapraz entropi fonksiyonu ile hesaplanmıştır.

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

Denklem(5)




Şekil 3. ROC Eğrisi

Şekil 3, modelin ROC eğrisini ve AUC-ROC skorunu (0.87) göstermektedir. ROC eğrisi, doğru pozitif oranı (TPR) ve yanlış pozitif oranı (FPR) arasındaki ilişkiyi görselleştirir.

$$TPR = \frac{TP}{TP+FN}, \quad FPR = \frac{FP}{FP+TN}$$


Denklem(6)



Şekil 4. Karışıklık Matrisi

Şekil 4, modelin karışıklık matrisini göstermektedir. Matris, 47,469 doğru negatif, 6,190 yanlış pozitif, 15,247 yanlış negatif ve 41,108 doğru pozitif sonucu içermektedir. Modelin doğruluk oranı şu şekilde hesaplanmıştır.

$$\text{Accuracy} = \frac{47,469 + 41,108}{47,469 + 41,108 + 15,247 + 6,190} = \frac{88,577}{110,014} \approx 0.8052 \text{ (yaklaşık \%80.52)} \quad \text{Denklem(7)}$$

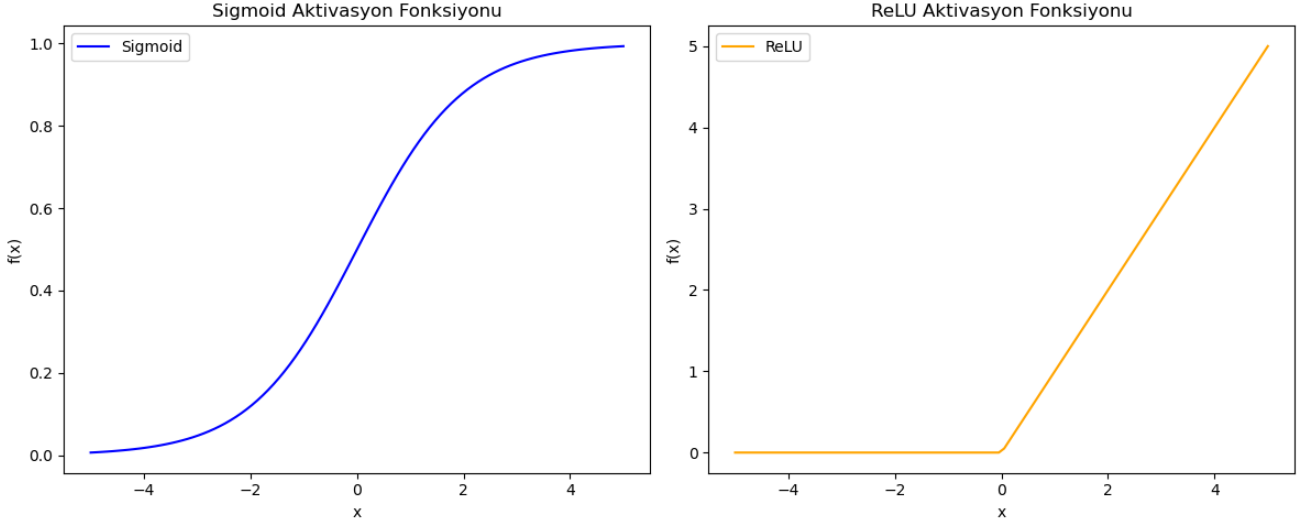


Şekil 5. Özellik Önem Sıralaması

Şekil 5, Permutation Importance yöntemiyle hesaplanan özellik önem sıralamasını göstermektedir. “Product_Category_1” en yüksek öneme sahipken, diğer kategoriler de önemli katkılar sağlamıştır. Özellik önemi şu şekilde hesaplanmıştır.

$$I_f = \frac{1}{K} \sum_{k=1}^K (S_{\text{normal}} - S_{\text{permütasyon},k})$$

Denklem(8)



Şekil 6. Sigmoid ve ReLU Aktivasyon Fonksiyonları

Şekil 6, sigmoid ve ReLU aktivasyon fonksiyonlarının giriş değerlerine (x eksen) göre çıkış değerlerini (y eksen) gösteren grafikleri içermektedir. Sigmoid grafiği (mavi çizgi), giriş değerleri arttıkça çıktının 0'dan 1'e S şeklinde yumuşak bir geçiş yaptığını gösterir; bu, ikili sınıflandırmada olasılık tahmini için idealdir çünkü çıktıyı [0,1] aralığına sıkıştırır. ReLU grafiği (turuncu çizgi) ise negatif girişlerde 0, pozitif girişlerde ise girişin kendisini verir; bu, modelin doğrusal olmayan ilişkileri öğrenmesini kolaylaştırır ve hesaplama maliyetini düşürür. Bu grafikler, her iki fonksiyonun modelin öğrenme sürecindeki rolünü görselleştirerek, sigmoid'ın çıkış katmanında sınıflandırma, ReLU'nun ise gizli katmanlarda verimliliği nasıl sağladığını açıklar.

4.1. Genel Değerlendirme

Model, 1 sınıfını (Purchase > 8000) %72.9 duyarlılıkla tahmin etti, hassasiyet ise %86.9 olarak ölçüldü. Özellik önem sıralamasında, Product_Category_1 ve Product_Category_2 değişkenlerinin tahmin gücünde baskın olduğu ortaya çıktı. Çalışma, e-ticaret işletmelerine müşteri segmentasyonu ve hedefli pazarlama stratejileri sunabilir. Gelecekte, LSTM veya Transformer gibi modeller ve ek veri setleri kullanılabilir (Fader et al., 2022).

5. KAYNAKÇA

- Chollet, F. (2015). Keras: Deep learning library for Theano and TensorFlow. <https://keras.io>
- Elma, O. E. (2014). Predicting Sales Revenue by Using Artificial Neural Network in Grocery Retailing Industry: A Case Study in Turkey. Academia.edu
- Deeper Deep Learning TR. (t.y.). Aktivasyon fonksiyonu. Medium. <https://medium.com/deeper-deep-learning-tr/aktivasyon-fonksiyonu-120769040f7b>
- Fader, P. S., Hardie, B. G., & Lee, K. L. (2022). Predictive Analytics for Customer Repurchase: Interdisciplinary Integration of Buy till You Die Modeling and Machine Learning. *European Journal of Operational Research*, 296(2), 635-651. <https://doi.org/10.1016/j.ejor.2021.05.008>
- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. arXiv preprint arXiv:1412.6980. <https://doi.org/10.48550/arXiv.1412.6980>
- Kumar, S., et al. (2023). Variable Aware Analytic Driven Online Shoppers Purchasing Intention using ML Algorithms. *International Journal for Research in Applied Science & Engineering Technology*, 11(5), 104-112. <https://www.ijraset.com>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Rahman, M. M., et al. (2023). Modeling online customer purchase intention behavior applying different feature engineering and classification techniques. *Discover Artificial Intelligence*, 3(1), 1-20. <https://doi.org/10.1007/s44163-023-00086-0>
- Sharma, A., et al. (2021). On the platform but will they buy? Predicting customers' purchase behavior using deep learning. *Electronic Commerce Research and Applications*, 49, 101092. <https://doi.org/10.1016/j.elerap.2021.101092>
- Statista. (2024). Global e-commerce market size and growth forecast. <https://www.statista.com>